

LAPORAN TUGAS BESAR

“MONITORING KEPATUHAN *PENGUNAAN PERSONAL PROTECTIVE EQUIPMENT* (PPE) KRU LAPANGAN BERBASIS YOLOV8N DENGAN OPTIMASI KUANTISASI DAN PRUNING UNTUK INFERENSI *EDGE AI* DI *BROWSER*”

(Studi Kasus 31: Monitoring Kepatuhan PPE Kru Lapangan)

MATA KULIAH DEEP LEARNING C-083



Diusulkan oleh Kelompok 4 :

Difta Alzena Sakhi (NPM. 23083010061)

Azizah Zalfa Assyadida (NPM. 23083010064)

Ni Luh Ayu Nariswari Dewi (NPM. 23083010068)

Karina Auralia (NPM. 23083010072)

Tiara Audrey Anugerah Hadin (NPM. 23083010079)

Dosen Pengampu :

Dr. I Gede Susrama Mas Diyasa, ST., MT.

Dosen Praktisi :

Kahpi Baiquni Arifani, S.Kom., M.Kom.

PROGRAM STUDI SAINS DATA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS PEMBANGUNAN NASIONAL “VETERAN” JAWA TIMUR

2026

Abstrak:

Pelanggaran pemakaian Alat Pelindung Diri (APD) di *rig floor*, dermaga, dan kilang meningkatkan risiko cedera fatal, sedangkan pengawasan manual melalui CCTV mengalami keterbatasan untuk dilakukan secara terus-menerus. Penelitian ini melatih YOLOv8n pralatih COCO dalam mendeteksi lima objek APD (*Helmet, Mask, Safety Vest, boots, glove*) pada dataset PPE Kaggle (8.243 latih, 2.357 validasi, 1.177 uji). Model dilatih 50 *epoch* pada GPU Tesla T4 lalu dievaluasi pada set uji yang tidak dipakai selama pelatihan. Model FP32 mencapai *precision* 0,894, *recall* 0,797, F1 0,843, mAP@0,5 0,860, dan mAP@0,5:0,95 0,576 dengan ukuran 5,96 MB. Dalam adaptasi *Edge AI*, model diekspor ke ONNX FP32 (11,73 MB), FP16 (5,91 MB), dan INT8 hasil *post-training quantization* (3,27 MB), serta diuji dengan *unstructured pruning* 30%. INT8 memperkecil ukuran ONNX 3,6 kali dengan *precision* tetap (0,895), tetapi mAP@0,5 turun 6,8 poin menjadi 0,792. *Pruning* 30% tanpa *fine-tuning* hanya menurunkan mAP@0,5 sebesar 1,4 poin, tetapi tidak mengecilkan ukuran berkas karena bentuk tensor tidak berubah. Kesalahan dominan adalah objek APD yang terlewat atau terdeteksi pada latar, bukan kekeliruan antarkelas.

Kata kunci: *PPE detection, YOLOv8 object detection, edge AI, HSSE, migas.*

1. Pendahuluan

APD seperti helm, pakaian kerja, sepatu, dan sarung tangan adalah lapisan perlindungan terakhir bagi kru di *rig floor*, dermaga, dan kilang. Pada anjungan lepas pantai, kru berisiko terjatuh dari ketinggian, tertimpa peralatan, dan tenggelam; pengawasan pemakaian APD masih banyak mengandalkan peninjauan manual rekaman CCTV yang rawan lelah dan subjektif [1]. Jumlah kamera yang besar juga membuat seluruh tayangan tidak mungkin dipantau manusia secara terus-menerus [1]. Deteksi objek berbasis deep learning, khususnya keluarga YOLO, kini menjadi pendekatan utama karena menyeimbangkan kecepatan dan akurasi [2], [3]. Namun penelitian di lingkungan migas umumnya memakai server GPU: RFA-YOLO diimplementasikan pada server yang masing-masing menangani 50 kamera [1], dan PSD-YOLO diuji pada GPU kelas desktop dengan catatan bahwa kuantisasi masih diperlukan untuk perangkat edge [2]. Gallo dkk. menunjukkan bahwa pemrosesan PPE di edge, bukan di cloud, layak untuk lingkungan industri [4].

Tabel 1 merangkum penelitian rujukan; angkanya tidak dapat dibandingkan langsung karena dataset, kelas, dan metriknya berbeda.


Tabel 1. Ringkasan penelitian rujukan

Rujukan	Data	Metode	Hasil Utama
Ji dkk., 2023 [1]	ODPD, citra CCTV anjungan pengeboran	RFA-YOLO (YOLOv4 + residual feature	Akurasi 93,1%, 13 FPS; kelas person, helm, workwear

Rujukan	Data	Metode	Hasil Utama
	lepas pantai (10.000 citra deteksi)	augmentation) + random forest posisi	
Qin dkk., 2025 [2]	13.202 citra pekerja anjungan minyak lepas pantai	PSD-YOLO (YOLOv10s + CAA, C2fCIB_Conv2Former, Soft-NMS)	mAP@0,5 82,5%, 232,56 FPS pada RTX 3090
Torres dkk., 2021 [5]	CCTV industri (kolaborasi Petrobras)	Komponen deteksi PPE real-time berbasis detektor deep learning	mAP 80,19%, 80 FPS
Wang dkk., 2021 [6]	CHV, 1.330 citra lokasi konstruksi, 6 kelas	Delapan varian YOLOv3/v4/v5	YOLOv5x mAP 86,55%; YOLOv5s 52 FPS pada GPU
Gallo dkk., 2022 [4]	Video pengawas lingkungan industri	Sistem deteksi PPE berbasis DNN di perangkat edge	Menggeser inferensi dari cloud ke edge

Kontribusi proyek ini, yaitu (1) pipeline YOLOv8n untuk lima kelas APD yang dievaluasi pada set uji terpisah dengan metrik *Precision*, *Recall*, F1, mAP@0,5, dan mAP@0,5:0,95; (2) perbandingan terukur tiga teknik optimasi *Edge AI*, yaitu ekspor FP16, *post-training quantization* INT8 [7], dan *unstructured pruning* 30% [8], terhadap akurasi dan ukuran berkas; serta (3) analisis kesalahan berbasis *confusion matrix* untuk menilai kesiapan model sebagai alat bantu pengawasan HSSE.

2. Metodologi



Gambar 1. Alur Penelitian

Alur penelitian terdiri atas delapan tahap (Gambar 1). Dataset PPE dari Kaggle diaudit (berkas *data.yaml*, jumlah citra, dan distribusi *instance* per kelas), lalu dipakai dengan *split* bawaan. Setiap citra diubah ukurannya menjadi 640×640 dan dilatih dengan augmentasi (*mosaic*, *flip*, HSV) pada YOLOv8n pralatih COCO selama 50 *epoch* di GPU Tesla T4. Model terbaik dievaluasi pada set uji dengan *Precision*, *Recall*, F1, mAP, dan *confusion matrix*, kemudian

dioptimasi untuk *Edge AI* melalui ekspor ONNX (FP32, FP16, INT8), *pruning* 30%, dan *benchmark* ukuran serta latensi. Tahap terakhir adalah aplikasi web di Vercel dengan tombol *Try Sample Data* dan inferensi model ONNX. Seluruh eksperimen dijalankan di Google Colab dengan Ultralytics 8.4.166 dan PyTorch 2.11.


2.1 Dataset dan split

Dataset PPE diunduh dari Kaggle melalui kagglehub [9], memakai versi Dataset_no_person_glasses berformat YOLO dengan lima kelas, yaitu *Helmet*, *Mask*, *Safety Vest*, *boots*, dan *glove*. Split bawaan dipakai apa adanya tanpa dibagi ulang dengan distribusi 8.243 citra latih (69,99%), 2.357 validasi (20,01%), dan 1.177 uji (9,99%) dari total 11.777 citra. Set uji memuat 158 citra latar tanpa objek dan hanya dipakai untuk evaluasi akhir.

Tabel 2. Jumlah *instance bounding box* per kelas.

Kelas	Latih	Validasi	Uji
Helmet	6.172	1.783	859
Mask	5.967	1.714	797
Glove	5.847	1.700	860
Boots	4.739	1.288	597
Safety Vest	4.578	1.393	638

Distribusi kelas dari data yang digunakan relatif seimbang, dengan kelas terkecil yaitu *Safety Vest*, 4.578 instance latih masih sekitar 74% dari kelas terbesar (*Helmet*, 6.172), sehingga tidak dilakukan penanganan *imbalanced* data khusus. Visualisasi *ground truth* menunjukkan citra berasal dari berbagai konteks, diantaranya jalan umum, kantor, laboratorium, dan foto produk, bukan khusus fasilitas migas dan dampaknya akan dibahas pada Subbab 3.4.



Gambar 2. Contoh anotasi *ground truth* pada data latih

2.2 Model dan pelatihan

Model yang dipakai adalah YOLOv8n [10], varian terkecil keluarga YOLOv8 [3], dengan bobot pralatih COCO (*transfer learning*; kepala deteksi diganti menjadi lima kelas). YOLOv8n dipilih karena tiga alasan: (1) ukurannya kecil, yaitu 3.006.623 parameter dan 8,1 GFLOPs setelah fusi layer, sehingga sesuai batas 20–30 MB untuk *Edge AI*; (2) bobot pralatih COCO mempercepat konvergensi pada dataset sekitar 11,8 ribu citra; dan (3) Ultralytics menyediakan ekspor ONNX dengan NMS tertanam serta opsi FP16 dan INT8. Model bersifat *anchor-free* dengan *backbone* berbasis blok C2f dan kepala deteksi terpisah untuk klasifikasi dan regresi kotak. Varian lain (mis. YOLOv8s atau YOLO11n) tidak dibandingkan, sehingga pemilihan ini didasarkan pada kesesuaian dengan batas ukuran, bukan pada perbandingan akurasi antarvarian.

Pelatihan berjalan 50 *epoch* pada GPU Tesla T4 dengan ukuran input 640×640, batch 16, *mixed precision* (AMP), dan *early stopping* patience 10. Karena parameter *optimizer* diset otomatis, Ultralytics memilih AdamW (lr 0,001111, momentum 0,9, *weight decay* 0,0005) dan mengabaikan lr 0 0,01. Bobot *loss* memakai nilai bawaan (box 7,5; klasifikasi 0,5; DFL 1,5). Augmentasi bawaan aktif selama pelatihan, antara lain *mosaic* (dimatikan pada 10 *epoch* terakhir), *flip* horizontal 0,5, jitter HSV, *scale* 0,5, translasi 0,1, *random erasing* 0,4, dan RandAugment; validasi dan pengujian tidak memakai augmentasi. Seed 42 diterapkan pada Python, NumPy, dan PyTorch, sedangkan seed Ultralytics memakai nilai bawaan (0). Pelatihan selesai penuh 50 *epoch* dalam 1,98 jam tanpa terpicu *early stopping*, dan *checkpoint* terbaik dipilih dari metrik validasi.

2.3 Optimasi Edge AI

Bobot terbaik diekspor ke ONNX (opset 18, input statis 1×3×640×640) dengan NMS tertanam, sehingga terbentuk keluaran 1×300×6 dan siap dipakai *runtime* seperti onnxruntime-web. Tiga varian optimasi diuji:

1. **FP16:** ekspor ONNX dengan bobot setengah presisi.
2. **INT8 (*post-training quantization statis*):** kuantisasi dengan ONNX Runtime [7], dikalibrasi memakai 25% data validasi (589 citra).
3. **Unstructured pruning 30%:** global L1 *pruning* pada bobot seluruh lapisan Conv2d kecuali modul DFL [8], lalu *mask* dipermanenkan. *Sparsity* terukur 30,00%. *Fine-tuning* 10 *epoch* (lr 0,001) juga dicoba dan hasilnya dibahas pada Subbab 3.3.

2.4 Protokol evaluasi


Semua varian dievaluasi pada set uji yang sama, yaitu 1.177 citra dan 3.751 *instance*. Metrik yang dilaporkan adalah *Precision* (P), *Recall* (R), mAP@0,5, dan mAP@0,5:0,95 dari validator Ultralytics. *Confusion matrix* dipakai untuk menganalisis jenis kesalahan. Efisiensi diukur dari ukuran berkas (MB) dan latensi *end-to-end predict* Ultralytics pada satu citra uji dengan 5 kali *warm-up*, median dari 20 pengulangan. Model PyTorch diukur pada GPU T4,

sedangkan seluruh model ONNX berjalan pada CPU Intel Xeon 2,00 GHz karena CUDAExecutionProvider tidak tersedia di *runtime*. Inferensi demo memakai *confidence threshold* 0,25 dan IoU NMS 0,50.

3. Hasil dan Pembahasan

3.1 Proses pelatihan

Pada proses pelatihan, $mAP@0,5$ validasi naik dari 0,607 pada *epoch* pertama menjadi 0,872 pada *epoch* ke-50, dan $mAP@0,5:0,95$ dari 0,332 menjadi 0,583, yang dapat dilihat pada Gambar 2. Kenaikan melambat pada sekitar 10 *epoch* terakhir ($mAP@0,5$ berkisar 0,865–0,872), tetapi belum berhenti sepenuhnya, sehingga *early stopping* tidak terpicu. Pada validasi, model terbaik mencapai *precision* 0,903 dan *recall* 0,801.



Gambar 3. Kurva loss dan metrik YOLOv8n selama 50 *epoch* pelatihan.

3.2 Evaluasi model FP32 pada set uji

Pada set uji, model FP32 mencapai *precision* 0,894, *recall* 0,797, F1 0,843, $mAP@0,5$ 0,860, dan $mAP@0,5:0,95$ 0,576. Selisihnya dengan validasi hanya 1,2 poin $mAP@0,5$, sehingga tidak terlihat *overfitting* yang berarti; *box loss* akhir juga berdekatan ($\pm 1,09$ pada data latih dan $\pm 1,19$ pada validasi).

Tabel 3. Performa per kelas model FP32 pada set uji dengan 1.177 citra dan 3.751 *instance*

Kelas	Instance	Precision	Recall	$mAP@0,5$	$mAP@0,5:0,95$
Mask	797	0,935	0,898	0,941	0,647
Boots	597	0,821	0,782	0,854	0,567
Helmet	859	0,919	0,784	0,839	0,548
Safety Vest	638	0,909	0,763	0,838	0,600
Glove	860	0,887	0,759	0,830	0,519
Semua	3.751	0,894	0,797	0,860	0,576

Mask adalah kelas termudah dengan *recall* 0,898. *Glove* memiliki $mAP@0,5:0,95$ terendah (0,519) yang berarti lokalisasi kotaknya paling kurang presisi, kemungkinan karena objeknya kecil. Pada semua kelas *precision* lebih tinggi daripada *recall*, dengan selisih rata-rata sekitar 10 poin. Untuk HSSE, pola ini berarti model jarang memberi alarm palsu tetapi masih melewatkan sekitar satu dari lima objek APD.

3.3 Efisiensi komputasi dan optimasi Edge AI

Tabel 4. Perbandingan varian optimasi pada set uji yang sama.

<i>Varian</i>	<i>Precision</i>	<i>Recall</i>	F1	mAP@ 0,5	mAP@ 0,5:0,95	Ukuran (MB)
FP32 PyTorch (<i>baseline</i>)	0,894	0,797	0,843	0,860	0,576	5,96
INT8 ONNX (PTQ)	0,895	0,775	0,831	0,792	0,531	3,27
Pruned 30% tanpa <i>fine-tuning</i>	0,885	0,775	0,826	0,847	0,561	5,99

INT8 memperkecil model ONNX dari 11,73 MB menjadi 3,27 MB (3,6 kali, atau 72% lebih kecil) dan 45% lebih kecil dari berkas .pt, dengan *precision* tetap. Namun $mAP@0,5$ turun 6,8 poin dan $mAP@0,5:0,95$ turun 4,5 poin, lebih besar daripada penurunan *recall* (2,2 poin). Penurunan $mAP@0,5$ terjadi di semua kelas (5,5–8,6 poin), terbesar pada *boots* (0,854 → 0,768) dan *glove* (0,830 → 0,756). Pola ini mengindikasikan kuantisasi menggeser urutan skor *confidence*, sehingga luas kurva *precision–recall* berkurang meski performa pada *threshold* operasional hampir sama. Kalibrasi hanya memakai 25% data validasi, dan ONNX Runtime memberi peringatan bahwa pra-pemrosesan model sebelum kuantisasi belum dilakukan; keduanya kandidat perbaikan.

Di sisi lain, pruning 30% tanpa *fine-tuning* hanya menurunkan $mAP@0,5$ sebesar 1,4 poin (0,860 → 0,847; selisih dari nilai tak dibulatkan), menandakan banyak bobot kecil YOLOv8n memang redundan. Karena *pruning* bersifat *unstructured*, bentuk tensor tidak berubah dan bobot nol tetap tersimpan, sehingga ukuran berkas tidak berkurang. Percobaan *fine-tuning* setelah *pruning* tidak berhasil: $mAP@0,5$ validasi pada *epoch* pertama hanya 0,069 dibanding *baseline* 0,607 dan berakhir 0,633 setelah 10 *epoch*. Penyebab pastinya belum diverifikasi. Dugaan kami, pelatihan diulang dengan *warmup* dan augmentasi penuh sementara *mask pruning* sudah dilepas, sehingga bobot yang dinolkan dapat terisi kembali. Model hasil *fine-tuning* tidak dipakai dalam perbandingan akurasi.

Tabel 5. Ukuran berkas dan latensi *end-to-end* per citra dengan median 20 pengulangan

Varian	Ukuran (MB)	Perangkat	Latensi median (ms)	Latensi p95 (ms)
FP32 PyTorch	5,96	GPU T4	11,82	13,38
Pruned PyTorch*	5,96	GPU T4	11,11	12,18


Varian	Ukuran (MB)	Perangkat	Latensi median (ms)	Latensi p95 (ms)
FP32 ONNX	11,73	CPU Xeon 2,00 GHz	101,01	114,43
FP16 ONNX	5,91	CPU Xeon 2,00 GHz	96,86	135,23
INT8 ONNX	3,27	CPU Xeon 2,00 GHz	171,00	257,68

Latensi model PyTorch dan ONNX tidak dapat dibandingkan langsung karena diukur pada perangkat berbeda. Di antara varian ONNX pada CPU yang sama, FP16 tidak memberi keuntungan latensi yang konsisten terhadap FP32 (median 96,86 vs 101,01 ms, dengan p95 lebih lebar), sedangkan INT8 justru paling lambat (171,00 ms) meski berkasnya terkecil. Dugaan kami, CPU pengukuran belum mendukung instruksi INT8 secara efisien dan terdapat *overhead* operator *quantize-dequantize*; dugaan ini belum diverifikasi. Semua varian berukuran di bawah 12 MB, jauh di bawah batas 20–30 MB pada panduan.

Aplikasi web menjalankan ONNX FP32 (11,73 MB). INT8 tidak dipilih karena mAP@0,5 turun 6,8 poin dan latensinya pada CPU pengukuran paling tinggi. FP16 (5,91 MB) tidak memberi keuntungan latensi yang konsisten dan akurasi belum divalidasi terpisah. FP16 dan INT8 tetap tersedia sebagai opsi jika ukuran unduhan menjadi prioritas.

3.4 Analisis error

Confusion matrix menunjukkan kekeliruan antarkelas hampir nol, yaitu paling banyak 2 objek per pasangan kelas. Kesalahan didominasi dua jenis, yaitu objek APD yang terlewat (diprediksi sebagai latar) dan deteksi palsu pada latar (Tabel 6).



Gambar 4. *Confusion matrix* model FP32 pada set uji.

Tabel 6. Ringkasan *confusion matrix* per kelas.

Kelas	Terdeteksi benar	Terlewat (latar)	Deteksi palsu pada latar
<i>Mask</i>	731	63	82
<i>Helmet</i>	691	167	88
<i>glove</i>	681	175	153
<i>boots</i>	507	88	176
Safety Vest	504	134	93

Glove dan *Helmet* paling sering terlewat, sedangkan *boots* dan *glove* paling sering muncul sebagai deteksi palsu. Kelas-kelas ini berukuran kecil dan kemungkinan mudah tertukar dengan tangan atau alas kaki biasa. Gambar 2 memperlihatkan bahwa label *boots* dan *Mask* juga diberikan pada sepatu dan masker non-industri, sehingga model mempelajari “alas kaki” dan “masker” secara umum, bukan *safety boots* atau respirator.



Gambar 5. Contoh deteksi pada citra uji dengan *confidence threshold* 0,25

Pada Gambar 5, model mendeteksi *Helmet* (0,87) dan *Safety Vest* (0,85), tetapi *glove* hanya 0,48. Dikarenakan dataset tidak memiliki kelas *Person*, model belum dapat mengaitkan APD dengan pekerja tertentu dan belum dapat menyimpulkan pelanggaran per individu.

4. Dampak Operasional, Efisiensi Biaya, dan Manajemen Risiko

Solusi ini menasar Pilar 1 (HSSE) dengan target *zero accident*, dan sebagian Pilar 3 (efisiensi biaya) melalui Edge AI. Skenario penggunaannya adalah penapisan otomatis cuplikan CCTV di *rig floor*, dermaga, dan kilang. Model menandai *frame* yang memuat APD terdeteksi atau tidak lengkap, lalu petugas HSE memverifikasi *frame* yang ditandai, bukan menonton seluruh rekaman.

Makna metrik bagi operasi. Pada ambang *confidence* yang memaksimalkan F1, *precision* 0,894 berarti sekitar 11 dari setiap 100 deteksi APD adalah deteksi palsu, dan *recall* 0,797 berarti sekitar 20 dari setiap 100 objek APD yang sebenarnya ada tidak terdeteksi. Dalam pengawasan kepatuhan, objek APD yang terlewat dapat memicu alarm "tidak memakai APD" yang keliru, sehingga verifikasi petugas HSE tetap diperlukan pada setiap alarm. Menurunkan ambang dari

0,25 (nilai pada demo dan *confusion matrix*) dapat menaikkan *recall* dengan risiko *precision* turun, sehingga nilai ambang sebaiknya ditentukan bersama pihak HSSE. Untuk aplikasi web, ONNX FP32 (11,73 MB) diusulkan sebagai model utama karena kompatibilitasnya paling luas dan bobotnya sama dengan model PyTorch yang akurasi telah diukur. ONNX INT8 (3,27 MB) disediakan sebagai opsi ringan jika ukuran berkas menjadi prioritas, dengan konsekuensi *recall* turun menjadi 0,775 (sekitar 22 dari 100 objek APD terlewat). Keputusan akhir menunggu pengukuran latensi di browser.

Efisiensi biaya komputasi. Sistem pada [1] memakai server yang masing-masing menangani 50 kamera secara bergiliran. Model kelompok ini berukuran 3,27–5,96 MB dan dapat dijalankan di sisi klien melalui ONNX, sehingga kebutuhan server GPU untuk inferensi dapat dihilangkan. Estimasi penghematan dalam rupiah memerlukan data kontrak perusahaan (jumlah kamera, biaya server atau cloud GPU, dan jam kerja petugas pemantau), sehingga tidak dihitung dalam laporan ini.

Tabel 7. Register risiko kualitatif penerapan sistem.

Bahaya atau risiko	Kontribusi sistem	Risiko sisa
Cedera kepala akibat benda jatuh saat helm tidak dipakai	Menandai <i>frame</i> tanpa deteksi <i>Helmet</i> untuk ditindaklanjuti	21,6% <i>instance Helmet</i> uji terlewat (<i>recall</i> 0,784)
Cedera tangan dan kaki pada pekerjaan pipa dan peralatan berat	Memantau <i>glove</i> dan <i>boots</i> secara terus-menerus	<i>Glove</i> dan <i>boots</i> memiliki deteksi palsu terbanyak (153 dan 176)
Kelelahan dan bias subjektif petugas pemantau CCTV [1]	Memindahkan pemantauan awal dari manusia ke model	Model tidak mengaitkan APD ke individu karena tidak ada kelas <i>Person</i>
Risiko baru, yaitu alarm palsu atau pelanggaran terlewat	-	Dikendalikan dengan verifikasi petugas HSE untuk setiap alarm

Batasan. Dataset tidak memuat *coverall* tahan api maupun kelas *Person*, dan citranya bukan dari fasilitas migas. Oleh karena itu, sistem ini belum dapat mengklaim penilaian kepatuhan APD per pekerja, maka hasilnya diposisikan sebagai *prototipe* deteksi objek APD yang perlu dilatih ulang dengan data *rig floor* atau kilang sebelum dipakai di lapangan.

5. Kesimpulan dan Saran

YOLOv8n pralatih COCO yang dilatih 50 *epoch* mendeteksi lima kelas APD dengan F1 0,843 dan mAP@0,5 0,860 pada set uji, dengan ukuran 5,96 MB. Kuantisasi INT8 menghasilkan model terkecil (3,27 MB) tetapi menurunkan mAP@0,5 sebesar 6,8 poin, sedangkan pruning 30% hanya menurunkan 1,4 poin tanpa mengecilkan berkas. Kesalahan utama adalah APD kecil (*glove*, *Helmet*) yang terlewat dan deteksi palsu pada latar, bukan kekeliruan antarkelas. Semua varian memenuhi batas ukuran Edge AI panduan.

Saran pengembangan, antara lain:

1. Memperbaiki *fine-tuning* setelah pruning agar melanjutkan bobot hasil *pruning*, atau mencoba *structured pruning* yang benar-benar mengecilkan tensor.
2. Mengevaluasi akurasi FP16 ONNX dan memperbaiki kalibrasi INT8 dengan data kalibrasi lebih banyak dan pra-pemrosesan ONNX Runtime sebelum memilih varian deploy.
3. Mengukur latensi seluruh varian di *browser* melalui *onnxruntime-web* pada perangkat yang sama.
4. Menambah data dari *rig floor*, dermaga, dan kilang, termasuk kelas *Person* dan *coverall* tahan api, agar sistem dapat menilai kepatuhan per pekerja seperti pada [1].
5. Melakukan uji dengan beberapa seed dan validasi pilot bersama tim HSE untuk mengganti kerangka biaya dengan data nyata.

Daftar Pustaka

- [1] X. Ji, F. Gong, X. Yuan, and N. Wang, "A high-performance framework for personal protective equipment detection on the offshore drilling platform," *Complex Intell. Syst.*, vol. 9, no. 5, pp. 5637–5652, 2023, doi: [10.1007/s40747-023-01028-0](https://doi.org/10.1007/s40747-023-01028-0).
- [2] Y. Qin, J. Dong, W. Li, L. Zhang, K. Feng, and Z. Wang, "PSD-YOLO: An enhanced real-time framework for robust worker detection in complex offshore oil platform environments," *Sensors*, vol. 25, no. 20, Art. no. 6264, 2025, doi: [10.3390/s25206264](https://doi.org/10.3390/s25206264).
- [3] J. Terven, D.-M. Córdova-Esparza, and J.-A. Romero-González, "A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS," *Mach. Learn. Knowl. Extr.*, vol. 5, no. 4, pp. 1680–1716, 2023, doi: [10.3390/make5040083](https://doi.org/10.3390/make5040083).
- [4] G. Gallo, F. Di Rienzo, F. Garzelli, P. Ducange, and C. Vallati, "A smart system for personal protective equipment detection in industrial environments based on deep learning at the edge," *IEEE Access*, vol. 10, pp. 110862–110878, 2022, doi: [10.1109/ACCESS.2022.3215148](https://doi.org/10.1109/ACCESS.2022.3215148).
- [5] P. Torres *et al.*, "A robust real-time component for personal protective equipment detection in an industrial setting," in *Proc. 23rd Int. Conf. Enterprise Inf. Syst. (ICEIS)*, vol. 1, 2021, pp. 693–700, doi: [10.5220/0010452606930700](https://doi.org/10.5220/0010452606930700).
- [6] Z. Wang, Y. Wu, L. Yang, A. Thirunavukarasu, C. Evison, and Y. Zhao, "Fast personal protective equipment detection for real construction sites using deep learning approaches," *Sensors*, vol. 21, no. 10, Art. no. 3478, 2021, doi: [10.3390/s21103478](https://doi.org/10.3390/s21103478).
- [7] B. Jacob *et al.*, "Quantization and training of neural networks for efficient integer-arithmetic-only inference," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2018, pp. 2704–2713, doi: [10.1109/CVPR.2018.00286](https://doi.org/10.1109/CVPR.2018.00286).

[8] T. Liang, J. Glossner, L. Wang, S. Shi, and X. Zhang, “Pruning and quantization for deep neural network acceleration: A survey,” *Neurocomputing*, vol. 461, pp. 370–403, 2021, doi: [10.1016/j.neucom.2021.07.045](https://doi.org/10.1016/j.neucom.2021.07.045).

[9] waquarahmed1, “PPE Dataset,” Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/waquarahmed1/ppe-dataset> (diakses [27 September 2026]).

[10] G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics YOLOv8,” GitHub, 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics> (versi yang dipakai: 8.4.166).

Lampiran A. *Contribution Statement*

Tabel A1. Pembagian peran dan kontribusi anggota Kelompok 4 (total 100%).

Nama (NPM)	Peran	Tanggung jawab	Kontribusi
Difta Alzena Sakhi (23083010061) Ketua	Model Architect & Quantization	Mengkoordinasikan pembagian tugas dan integrasi hasil kerja tim; merancang arsitektur solusi YOLOv8n; menentukan konfigurasi pelatihan; menjalankan eksperimen quantization INT8, ekspor ONNX, dan pruning; menganalisis hasil performa model serta mengoordinasikan penyusunan laporan akhir.	25%
Azizah Zalfa Assyadida (23083010062)	Data Pipeline & Augmentation	Mengunduh dan menyiapkan dataset PPE; memeriksa struktur data.yaml, format anotasi, jumlah citra, dan distribusi instance setiap kelas; memvalidasi split train-validation-test; menyiapkan preprocessing dan augmentasi seperti resize 640×640 , mosaic, horizontal flip, dan HSV augmentation; mendokumentasikan karakteristik serta keterbatasan dataset.	20%
Ni Luh Ayu Nariswari Dewi (23083010068)	Edge Runtime & Inference Optimization	Menyiapkan ekspor model ke ONNX FP32 dan FP16; menjalankan post-training quantization INT8; menerapkan dan mengevaluasi unstructured pruning 30%; mengukur	20%

Nama (NPM)	Peran	Tanggung jawab	Kontribusi
		ukuran model dan latency inferensi; menguji kompatibilitas model dengan ONNX Runtime; menganalisis trade-off antara ukuran model, kecepatan, dan performa deteksi.	
Karina Auralia (23083010072)	Frontend & Integrasi Web	Mengembangkan dan mengintegrasikan antarmuka aplikasi web; menyiapkan fitur upload citra dan Try Sample Data; menghubungkan aplikasi Flask dengan model ONNX Runtime; menampilkan bounding box, label kelas, dan confidence score; mengatur aset visual, halaman profil tim, serta melakukan deployment dan pengujian aplikasi pada Vercel.	20%
Tiara Audrey Anugerah Hadin (23083010079)	Technical Writer & Validasi HSE	Menyusun dokumentasi teknis dan laporan ilmiah; melakukan studi literatur terkait PPE detection, YOLO, Edge AI, quantization, dan pruning; menyusun bagian pendahuluan, metodologi, hasil, pembahasan, dampak HSSE, kesimpulan, dan daftar pustaka; memvalidasi kesesuaian solusi dengan konteks keselamatan kerja serta melakukan proofreading dan pengecekan format laporan.	15%

Lampiran B. Artefak Proyek

- Repositori GitHub (publik) :
<https://github.com/KarinaAuralia/Project-Deep-Learning-PPE/tree/main>
- Aplikasi web :
<https://ppe-kelompok4.vercel.app/>
- Notebook:
https://colab.research.google.com/drive/14ce_tnC6-DRbuNaucirsmbVvBVXNneeQ#scrollTo=USvCbXTXfTIg

