



TUGAS BESAR DEEP LEARNING C-083 · KELOMPOK 4 · KASUS 31

Program Studi Sains Data · UPN “Veteran” Jawa Timur

Monitoring Kepatuhan PPE Kru Lapangan berbasis YOLOv8n

Optimasi kuantisasi dan pruning untuk inferensi Edge AI di browser

Difta Alzena Sakhi (Ketua) · Azizah Zalfa Assyadida · Ni Luh Ayu Nariswari Dewi · Karina Auralia · Tiara Audrey

Dosen pengampu: Dr. I Gede Susrama Mas Diyasa, ST., MT.

Dosen praktisi: Kahpi Baiquni Arifani, S.Kom., M.Kom.



Contoh keluaran model (confidence 0,25)

Kepatuhan APD sulit diawasi secara manual

Rig floor, dermaga, dan kilang: APD adalah lapisan perlindungan terakhir bagi kru.



Risiko kru lapangan

Di anjungan lepas pantai, kru berisiko jatuh dari ketinggian, tertimpa peralatan, dan tenggelam. Pelanggaran APD meningkatkan risiko cedera fatal [1].



Pengawasan CCTV manual

Peninjauan rekaman rawan lelah dan subjektif. Jumlah kamera yang besar membuat seluruh tayangan tidak mungkin dipantau terus-menerus [1].



Celah: Edge AI

Penelitian YOLO di migas umumnya memakai server GPU [1], [2]. Pemrosesan PPE di edge terbukti layak untuk industri [4].

Tujuan: detektor 5 kelas APD (Helmet, Mask, Safety Vest, boots, glove) berbasis YOLOv8n [3], [10] yang ringan, dioptimasi dengan INT8 dan pruning agar bisa berjalan di browser sebagai alat bantu pengawasan HSSE.

Dataset PPE Kaggle: 5 kelas, split bawaan

Dataset PPE dari Kaggle [9] berformat YOLO. Pembagian data latih/validasi/uji bawaan dipakai apa adanya.

8.243

citra latih (69,99%)



2.357

citra validasi (20,01%)

1.177

citra uji (9,99%)

Instance bounding box per kelas



Contoh anotasi ground truth pada data latih

Kelas relatif seimbang

Safety Vest (4.578) $\pm 74\%$ dari Helmet (6.172). Set uji memuat 158 citra latar. Citra berasal dari jalan, kantor, laboratorium, dan foto produk, bukan khusus migas.

YOLOv8n: model deteksi terkecil, dilatih 50 epoch

YOLOv8n [10] adalah varian YOLO paling ringan [3]; dilatih lanjut dari bobot COCO (transfer learning).

3,0 jt

parameter (3.006.623)


8,1

GFLOPs

1,98 jam

waktu training penuh

Pengaturan	Nilai
Input / batch	640×640 / 16
Optimizer / lr0	Otomatis Ultralytics / 0,01
Presisi	Mixed precision (AMP)
Early stopping	Patience 10 (tidak terpicu)
Augmentasi	Mosaic, flip 0,5, jitter HSV, random erasing 0,4



Kurva loss dan metrik selama 50 epoch

mAP@0,5 validasi 0,607 → 0,872 dan **mAP@0,5:0,95 0,332 → 0,583**.
Kenaikan melambat di ±10 epoch terakhir, checkpoint terbaik dipilih dari metrik validasi.

Cara membaca hasil: empat angka kunci

Semakin mendekati 1,0 semakin baik. Contoh: model mencari APD di foto.



Precision

Kalau model bilang “ini helm”, seberapa sering benar?

Rendah = banyak alarm palsu.



Recall

Dari semua APD yang ada di foto, berapa yang berhasil ditemukan?

Rendah = banyak APD terlewat.



F1

Gabungan Precision dan Recall dalam satu angka.

Tinggi hanya jika keduanya tinggi.



mAP

Skor ketepatan deteksi semua kelas. mAP@0,5: kotak benar jika tumpang tindih $\geq 50\%$ dengan label; mAP@0,5:0,95 lebih ketat.

Angka utama untuk membandingkan model.

Contoh ilustrasi: ada 100 APD di foto. Model menandai 90 kotak dan 80 di antaranya benar $\rightarrow$ Precision = $80/90 \approx 0,89$ dan Recall = $80/100 = 0,80$. Hasil model kami di set uji: Precision 0,894 dan Recall 0,797.

FP32 mencapai mAP@0,5 0,860 pada set uji

1.177 citra, 3.751 instance. Model 5,96 MB, tanpa overfitting berarti (selisih validasi 1,2 poin).

0,894

Precision

0,797


Recall

0,843

F1

0,576

mAP@0,5:0,95



Precision > recall di semua kelas (selisih ± 10 poin): model jarang memberi alarm palsu, tetapi masih melewatkan sekitar 1 dari 5 objek APD. Mask paling mudah (recall 0,898); glove punya mAP@0,5:0,95 terendah (0,519) karena objeknya kecil.

Empat istilah optimasi

Tujuannya satu: model cukup kecil dan cepat untuk berjalan di browser.



Edge AI

AI dijalankan langsung di perangkat pengguna (di sini: browser), bukan di server GPU. Cocok untuk pengawasan yang harus hemat biaya server [4].



ONNX

Format berkas model yang bisa dijalankan di banyak platform, termasuk browser lewat onnxruntime-web.



Kuantisasi INT8

Bobot model disimpan sebagai bilangan bulat 8-bit, bukan desimal 32-bit. Seperti memampatkan foto: file lebih kecil, tetapi ada detail yang bisa hilang [7].



Pruning

Membuang bobot yang nilainya kecil dan dianggap kurang berguna, seperti memangkas ranting. Pada unstructured pruning bobot hanya dinolkan, sehingga ukuran file tidak berubah [8].

Dua teknik optimasi Edge AI diuji

Dari bobot terbaik FP32; keduanya dievaluasi pada set uji yang sama (1.177 citra).



INT8 (PTQ statis) [7]

Bobot model diperkecil dari 32-bit ke 8-bit setelah pelatihan, dikalibrasi dengan 589 citra validasi.

3,27 MB

3,6× lebih kecil dari ONNX FP32 (11,73 MB)

Precision tetap 0,895, tetapi mAP@0,5 turun 6,8 poin (0,860 → 0,792) dan recall turun ke 0,775. Penurunan terbesar pada boots dan glove.



Pruning 30% [8]

Memotong (menolkan) 30% bobot terkecil di seluruh lapisan konvolusi, tanpa pelatihan ulang.

-1,4 poin

mAP@0,5 0,860 → 0,847

Ukuran berkas tetap 5,99 MB: bobot yang dinolkan masih ikut tersimpan. Agar file benar-benar mengecil dibutuhkan structured pruning.


Catatan FP16: ONNX FP16 (5,91 MB) juga diekspor, tetapi hanya diukur ukuran dan latensinya. Akurasinya belum dievaluasi, sehingga tidak dibandingkan di sini.

INT8 terkecil, pruning paling akurat

Metrik pada set uji yang sama. Nilai terbaik per kolom ditebalkan.

Varian	Precision	Recall	F1	mAP50	mAP50-95	Ukuran
FP32 baseline	0,894	0,797	0,843	0,860	0,576	5,96 MB
INT8 ONNX (PTQ)	0,895	0,775	0,831	0,792	0,531	3,27 MB
Pruned 30%	0,885	0,775	0,826	0,847	0,561	5,99 MB

Pruned: 30% tanpa fine-tuning. INT8: ukuran model ONNX.



INT8

Ukuran 3,6× lebih kecil dari ONNX FP32, tetapi mAP50 turun 6,8 poin dan recall 2,2 poin.

Pruning 30%

mAP50 hanya turun 1,4 poin, tetapi ukuran berkas tidak berubah (5,99 MB).

Precision


Hampir sama di ketiganya (0,894 / 0,895 / 0,885); yang turun adalah recall, artinya lebih banyak APD terlewat.

Benchmark ukuran dan latensi per citra

Median = waktu tengah dari 20 uji; p95 = 95% uji selesai dalam waktu ini. GPU dan CPU tidak setara.

Model	Perangkat	Ukuran (MB)	Median (ms)	p95 (ms)
FP32 PyTorch	GPU T4	5,96	11,82	13,38
Pruned PyTorch*	GPU T4	5,96	11,11	12,18
FP32 ONNX	CPU Xeon 2,00 GHz	11,73	101,01	114,43
FP16 ONNX	CPU Xeon 2,00 GHz	5,91	96,86	135,23
INT8 ONNX	CPU Xeon 2,00 GHz	3,27	171,00	257,68

*Memakai model hasil fine-tuning; arsitektur sama dengan baseline sehingga latensinya setara.




Di web (Vercel) dipakai **ONNX FP32 (11,73 MB)**. FP16 setara FP32; INT8 justru paling lambat di CPU ini.

Error utama: APD terlewat dan deteksi palsu

Kekeliruan antarkelas hampir nol (maksimal 2 objek per pasangan kelas).



Confusion matrix model FP32 pada set uji



Glove dan Helmet paling sering terlewat; boots dan glove paling sering muncul sebagai deteksi palsu. Objek kecil ini mudah tertukar dengan tangan atau alas kaki biasa.

Dataset belum mewakili rig floor dan kilang

Prototipe deteksi objek APD, belum penilaian kepatuhan per pekerja.

PPE Detection — r89_jpg.rf.25f58db7e2decb2c79ef6a36395d4f6d.jpg

模特实拍展示

拍摄过程由于灯光等原因存在细微差异，请以收到实物为准



Foto katalog produk, confidence 0,25

Contoh deteksi



Helmet (0,87) dan Safety Vest (0,85) terdeteksi yakin, glove hanya 0,48. Citra ini contoh ketidakcocokan domain dengan kondisi lapangan.

Label terlalu umum



Kelas boots dan Mask juga diberikan pada sepatu dan masker non-industri, sehingga model belajar “alas kaki” dan “masker” secara umum.

Tanpa kelas Person



APD belum bisa dikaitkan ke pekerja tertentu, jadi pelanggaran per individu belum bisa disimpulkan. Coverall tahan api juga tidak ada.

Alat bantu petugas HSE, bukan pengganti

Model menandai frame CCTV; petugas HSE memverifikasi setiap alarm.

±11 / 100

deteksi APD adalah deteksi palsu (precision 0,894)

±20 / 100

objek APD tidak terdeteksi (recall 0,797)

Bahaya / risiko	Kontribusi sistem	Risiko sisa
Cedera kepala akibat benda jatuh	Menandai frame tanpa deteksi Helmet	21,6% Helmet uji terlewat
Cedera tangan dan kaki	Memantau glove dan boots terus-menerus	Deteksi palsu terbanyak (153 dan 176)
Kelelahan petugas CCTV [1]	Pemantauan awal oleh model	Tanpa kelas Person, tak terkait individu
Risiko baru: alarm palsu / terlewat	-	Verifikasi petugas HSE tiap alarm

Efisiensi biaya: web Vercel menjalankan ONNX FP32 (11,73 MB, di bawah batas 20–30 MB) di sisi klien, sehingga server GPU untuk inferensi dapat dihilangkan. Estimasi rupiah butuh data kontrak (jumlah kamera, biaya server, jam petugas), jadi belum dihitung.

Kesimpulan dan saran pengembangan



Kesimpulan

- YOLOv8n mendeteksi 5 kelas APD dengan F1 0,843 dan mAP@0,5 0,860 (5,96 MB).
- INT8 menghasilkan model terkecil (3,27 MB), tetapi mAP@0,5 turun 6,8 poin.
- Pruning 30% hanya turun 1,4 poin, namun ukuran berkas tidak mengecil.
- Error utama: APD kecil terlewat dan deteksi palsu pada latar, bukan tertukar antarkelas.
- Semua varian memenuhi batas ukuran Edge AI panduan.



Saran pengembangan

- Perbaiki fine-tuning setelah pruning atau coba structured pruning.
- Evaluasi akurasi FP16 dan perbaiki kalibrasi INT8 sebelum memilih varian deploy.
- Ukur latensi semua varian di browser (onnxruntime-web).
- Tambah data rig floor, dermaga, kilang, termasuk kelas Person dan coverall.
- Uji beberapa seed dan pilot bersama tim HSE.

Daftar Pustaka

Format IEEE, sesuai laporan; nomor sama dengan sitasi [n] di slide.

[1] X. Ji, F. Gong, X. Yuan, and N. Wang, "A high-performance framework for personal protective equipment detection on the offshore drilling platform," *Complex Intell. Syst.*, vol. 9, no. 5, pp. 5637–5652, 2023, doi: 10.1007/s40747-023-01028-0.

[2] Y. Qin, J. Dong, W. Li, L. Zhang, K. Feng, and Z. Wang, "PSD-YOLO: An enhanced real-time framework for robust worker detection in complex offshore oil platform environments," *Sensors*, vol. 25, no. 20, Art. no. 6264, 2025, doi: 10.3390/s25206264.

[3] J. Terven, D.-M. Córdova-Esparza, and J.-A. Romero-González, "A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS," *Mach. Learn. Knowl. Extr.*, vol. 5, no. 4, pp. 1680–1716, 2023, doi: 10.3390/make5040083.

[4] G. Gallo, F. Di Rienzo, F. Garzelli, P. Ducange, and C. Vallati, "A smart system for personal protective equipment detection in industrial environments based on deep learning at the edge," *IEEE Access*, vol. 10, pp. 110862–110878, 2022, doi: 10.1109/ACCESS.2022.3215148.

[5] P. Torres *et al.*, "A robust real-time component for personal protective equipment detection in an industrial setting," in *Proc. 23rd Int. Conf. Enterprise Inf. Syst. (ICEIS)*, vol. 1, 2021, pp. 693–700, doi: 10.5220/0010452606930700.

[6] Z. Wang, Y. Wu, L. Yang, A. Thirunavukarasu, C. Evison, and Y. Zhao, "Fast personal protective equipment detection for real construction sites using deep learning approaches," *Sensors*, vol. 21, no. 10, Art. no. 3478, 2021, doi: 10.3390/s21103478.

[7] B. Jacob *et al.*, "Quantization and training of neural networks for efficient integer-arithmetic-only inference," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2018, pp. 2704–2713, doi: 10.1109/CVPR.2018.00286.

[8] T. Liang, J. Glossner, L. Wang, S. Shi, and X. Zhang, "Pruning and quantization for deep neural network acceleration: A survey," *Neurocomputing*, vol. 461, pp. 370–403, 2021, doi: 10.1016/j.neucom.2021.07.045.

[9] waquarahmed1, "PPE Dataset," Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/waquarahmed1/ppe-dataset>

[10] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLOv8," GitHub, 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics> (versi 8.4.166).

Mari coba langsung di web



Pindai untuk membuka web

<https://ppe-kelompok4.vercel.app/>

1. Klik Try Sample Data: Rig Floor, Dermaga, atau Kilang
2. Atau unggah foto sendiri
3. Lihat hasil deteksi APD langsung di browser